Česká zemědělská univerzita v Praze

Provozně ekonomická fakulta

Statistické postupy Data Mining

Semestrální projekt – Bank Marketing

Ondřej Kotala, Daiana Bikmaeva, Robert Sládek, Pavel Dikan

2025 © ČZU v Praze

Contents

1. Business Understanding 3

2. Data Understanding 4

2.1. Metodika průzkumu dat 4

2.2. Deklarace proměnných 5

2.3. Kvalita dat a chybějící hodnoty 6

2.3.2 Skryté chybějící hodnoty 6

2.3.2 Odlehlé a nestandardní hodnoty 8

2.3.3. Proměnná campaign 9

2.3.4. Proměnná duration 10

2.4. Analýza cílové proměnné 10

2.5. Vztahy a korelace 11

2.5.1 Multikolinearita makroekonomických ukazatelů 11

2.5.2. Analýza délky hovoru 12

3. Data Preparation 12

3.1. Odstranění proměnné duration (Uzel Filter) 13

3.2. Ošetření chybějících hodnot 13

3.2.1. Odstranění proměnné default (Uzel Filter) 13

3.2.2. Filtrace záznamů u job a marital (Uzel Select) 13

3.2.3. Ponechání kategorie "unknown" 14

3.3. Transformace proměnné pdays (Uzel Derive) 14

3.4. Ošetření odlehlých hodnot 15

3.5. Odstranění multikolinearity 16

1. Business Understanding

Tento projekt je založen na reálných datech portugalské banky, která prováděla přímé marketingové kampaně. Hlavním způsobem komunikace byly telefonní hovory. Hromadné obvolávání všech klientů se ukázalo jako příliš nákladné a málo efektivní. Navíc časté telefonáty lidem, kteří nemají o službu zájem, mohou zhoršit jejich vztah k bance. V důsledku toho zaměstnanci tráví mnoho času hovory, které končí odmítnutím. Proto je nutné, aby banka optimalizovala proces a přešla od hromadného přístupu k cílenému.

V rámci metodiky CRISP-DM je hlavním úkolem sestavit prediktivní model binární klasifikace. Cílem modelu je na základě historických údajů o klientech a aktuálních ekonomických podmínek předpovědět cílovou proměnnou y, zda si klient sjedná termínovaný vklad ("ano" nebo "ne"). To umožní vybrat klienty s vysokou pravděpodobností kladné odezvy a zaměřit úsilí právě na ně.

Z obchodního hlediska není úspěch projektu určen pouze přesností modelu, protože třídy jsou velmi nevyvážené. Hlavním kritériem je schopnost modelu snížit náklady na marketing. Model je považován za úspěšný, pokud pomáhá výrazně snížit počet zbytečných hovorů (těch, kde klient stejně řekne "ne"), přičemž zachovává maximum úspěšných prodejů.

Cílem projektu je tedy zvýšit efektivitu práce call centra a zvýšit konverzi, to znamená podíl úspěšných transakcí z celkového počtu hovorů.

2. Data Understanding

2.1. Metodika průzkumu dat

Pro analýzu dat byl použit nástroj IBM SPSS Modeler. Hlavní fáze průzkumné analýzy byla provedena pomocí uzlu Data Audit, který umožnil automaticky vypočítat základní statistické ukazatele (průměr, medián, směrodatná odchylka) a vizualizovat rozložení proměnných.

Výzkum byl proveden ve třech fázích:

- Analýza struktury
  - Kontrola typů dat a rolí proměnných.
- Jednorozměrná analýza
  - Hledání chybějících hodnot (včetně skrytých chyb, jako je "unknown").
  - Kontrola nerovnováhy cílové proměnné a analýza odchylek.
- Dvourozměrná analýza
  - Zkoumání korelací mezi číselnými proměnnými a závislostí mezi kategorickými znaky a cílovou proměnnou.

2.2. Deklarace proměnných

Dataset použitý v tomto projektu obsahuje celkem 41 188 záznamů o realizovaných telefonických hovorech v rámci marketingové kampaně portugalské banky. Data byla sbírána v období od května 2008 do června 2013.

Každý záznam reprezentuje jednoho osloveného klienta a výsledek hovoru. Jedná se o reálná data, která byla anonymizována pro potřeby výzkumu.

Variable Name	Type (SPSS Modeler)	Role	Popis
age	Continuous	Input	Věk klienta.
job	Nominal	Input	Typ zaměstnání.
marital	Nominal	Input	Rodinný stav.
education	Nominal	Input	Dosažené vzdělání.
default	Nominal (Flag)	Input	Má úvěr v prodlení?
housing	Nominal (Flag)	Input	Má úvěr na bydlení?
loan	Nominal (Flag)	Input	Má osobní půjčku?
contact	Nominal	Input	Typ komunikačního zařízení.
month	Nominal	Input	Měsíc posledního kontaktu.
day_of_week	Nominal	Input	Den v týdnu posledního kontaktu.
duration	Continuous	Input	Doba trvání posledního hovoru v sekundách.
campaign	Continuous	Input	Počet kontaktů s klientem během této kampaně.
pdays	Continuous	Input	Počet dní od posledního kontaktu v předchozí kampani.
previous	Continuous	Input	Počet kontaktů před touto kampaní.
poutcome	Nominal	Input	Výsledek předchozí marketingové kampaně.
emp.var.rate	Continuous	Input	Míra variace zaměstnanosti.
cons.price.idx	Continuous	Input	Index spotřebitelských cen.
cons.conf.idx	Continuous	Input	Index spotřebitelské důvěry.
euribor3m	Continuous	Input	Sazba euribor 3 měsíce.
nr.employed	Continuous	Input	Počet zaměstnanců.
y	**Flag (Nominal)**	**Target**	**Cílová proměnná** Upsal klient termínovaný vklad?

Tabulka 1: Deklarace proměnných

2.3. Kvalita dat a chybějící hodnoty

Provedli jsme audit dat pomocí uzlu Data Audit. Technická analýza ukazuje, že datový soubor neobsahuje žádné prázdné hodnoty (NULL) v technickém smyslu. Všechny proměnné mají 100% naplněnost.

Field	Measurement	Outliers	Extremes	Action	Impute Missing	Method	% Complete
age	Continuous	365	4	None	Never	Fixed	100
job	Nominal	--	--	--	Never	Fixed	100
marital	Nominal	--	--	--	Never	Fixed	100
education	Nominal	--	--	--	Never	Fixed	100
default	Nominal	--	--	--	Never	Fixed	100
housing	Nominal	--	--	--	Never	Fixed	100
loan	Nominal	--	--	--	Never	Fixed	100
contact	Flag	--	--	--	Never	Fixed	100
month	Nominal	--	--	--	Never	Fixed	100
day_of_week	Nominal	--	--	--	Never	Fixed	100
duration	Continuous	684	177	None	Never	Fixed	100
campaign	Continuous	565	304	None	Never	Fixed	100
pdays	Continuous	0	1515	None	Never	Fixed	100
previous	Continuous	754	310	None	Never	Fixed	100
poutcome	Nominal	--	--	--	Never	Fixed	100
emp.var.rate	Continuous	0	0	None	Never	Fixed	100
cons.price.idx	Continuous	0	0	None	Never	Fixed	100
cons.conf.idx	Continuous	0	0	None	Never	Fixed	100
nr.employed	Continuous	0	0	None	Never	Fixed	100
terminovany_...	Flag	--	--	--	Never	Fixed	100

Obrázek 1: Celkové hodnocení kvality

2.3.2 Skryté chybějící hodnoty

Přestože data neobsahují systémové chybějící hodnoty, v kategoriálních proměnných (job, education, housing a další) se vyskytuje hodnota "unknown". Tuto hodnotu považujeme za sémanticky chybějící údaj.

Analýza četností ukazuje následující zastoupení hodnoty 'unknown' v kategorických proměnných:

- Default: 8 597 záznamů (20,9 %)
- Education: 1 731 záznamů (4,2 %)
- Housing: 990 záznamů (2,4 %)
- Loan: 990 záznamů (2,4 %)
- Job: 330 záznamů (0,8 %)
- Marital: 80 záznamů (0,2 %)

Value	Proportion	%	Count
admin.		25.3	10422
blue-collar		22.47	9254
entrepreneur		3.54	1456
housemaid		2.57	1060
management		7.1	2924
retired		4.18	1720
self-employed		3.45	1421
services		9.64	3969
student		2.12	875
technician		16.37	6743
unemployed		2.46	1014
unknown		0.8	330

Obrázek 2: Unknown in Job

Value	Proportion	%	Count
basic.4y		10.14	4176
basic.6y		5.56	2292
basic.9y		14.68	6045
high.school		23.1	9515
illiterate		0.04	18
professional.course		12.73	5243
university.degree		29.54	12168
unknown		4.2	1731

Obrázek 3: Unknown in Education

Value	Proportion	%	Count
no		79.12	32588
unknown		20.87	8597
yes		0.01	3

Obrázek 4: Unknown in Default

Value	Proportion	%	Count
no		45.21	18622
unknown		2.4	990
yes		52.38	21576

Obrázek 5: Unknown in Housing

Value	Proportion	%	Count
divorced		11.2	4612
married		60.52	24928
single		28.09	11568
unknown		0.19	80

Obrázek 6: Unknown in Marital

Value	Proportion	%	Count
no		82.43	33950
unknown		2.4	990
yes		15.17	6248

Obrázek 7: Unknown in Loan

Přestože data neobsahují systémové chybějící hodnoty, v kategoriálních proměnných (job, education, housing a další) se vyskytuje hodnota "unknown". Tuto hodnotu považujeme za sémanticky chybějící údaj.

Identifikovali jsme 6 proměnných obsahující hodnotu "unknown". Rozhodli jsme se pro diferencovaný přístup:

Odstranění proměnné (default)
Tato proměnná obsahuje 21 % hodnot "unknown" a extrémně nízkou variabilitu (téměř žádné hodnoty "yes"). Bude proto kompletně vyřazena z datasetu.

Odstranění záznamů (job, marital)
U těchto proměnných je podíl neznámých hodnot zanedbatelný (< 1 %). Záznamy s touto hodnotou byly odfiltrovány, aby nezanášely model šumem.

Ponechání kategorie (education, housing, loan)
Zde "unknown" tvoří významnější podíl (až 4 %). Tuto hodnotu jsme ponechali jako samostatnou kategorii, protože neochota sdělit tyto údaje může korelovat s ochotou koupit produkt.

2.3.2 Odlehlé a nestandardní hodnoty

V rámci kontroly numerických proměnných byla identifikována anomálie v proměnné "pdays". Většina hodnot je rovna 999. Podle dokumentace k datům hodnota 999 neznamená počet dní, ale fakt, že klient nebyl v minulosti kontaktován.

Toto není chyba v datech, ale specifický kódování, které budeme muset ošetřit ve fázi Data Preparation. Například vytvoříme nový příznak "Nový klient".

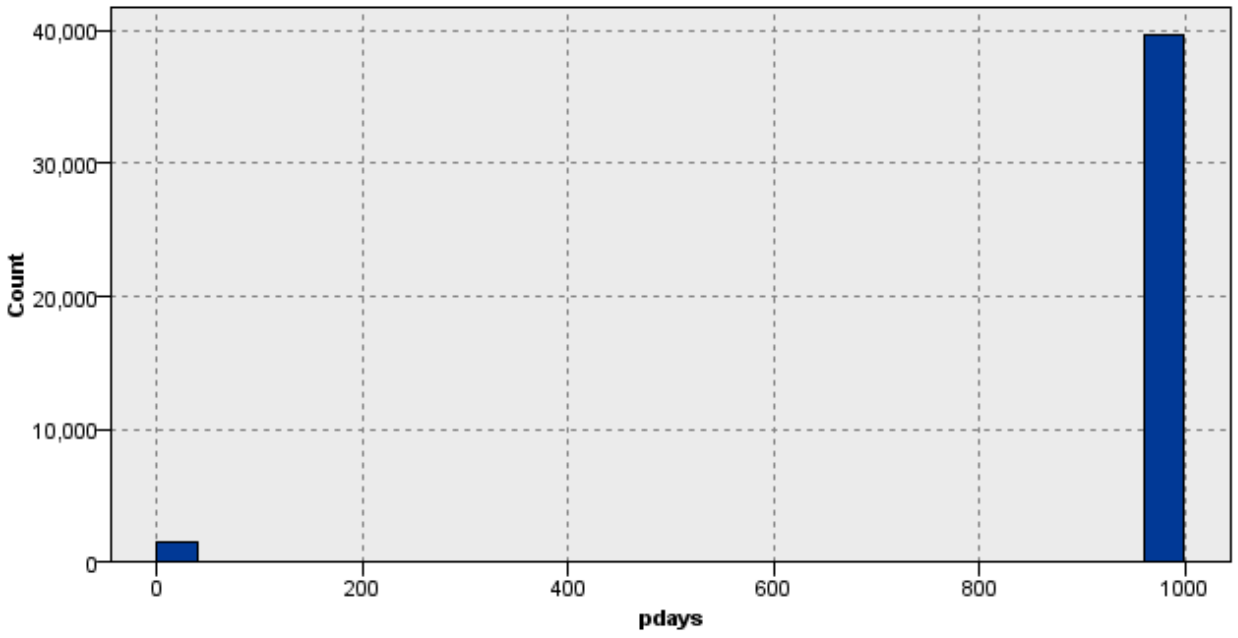

Obrázek 8: Anomálie v proměnné "pdays"

Histogram proměnné pdays ukazuje, že data se dělí na dvě zřetelné skupiny. Hodnota 999 představuje největší část vzorku. Jedná se o servisní hodnotu, která znamená, že klient nebyl nikdy dříve kontaktován. Hodnoty 0–30 představují malou skupinu klientů, kteří byli kontaktováni nedávno.

Použít pdays v původní podobě nelze. Hodnota 999 matematicky vypadá jako "velmi dávno", ale ve skutečnosti znamená "nikdy". Proto proměnnou převedeme na binární znak "is_new_client", který ukazuje, zda byl klient dříve kontaktován.

2.3.3. Proměnná campaign

Absolutní většina zákazníků (více než 90 %) obdržela 1 až 3 hovory. Existuje však „dlouhý ocas“ vzácných extrémních hodnot, které dosahují až 56 kontaktů.

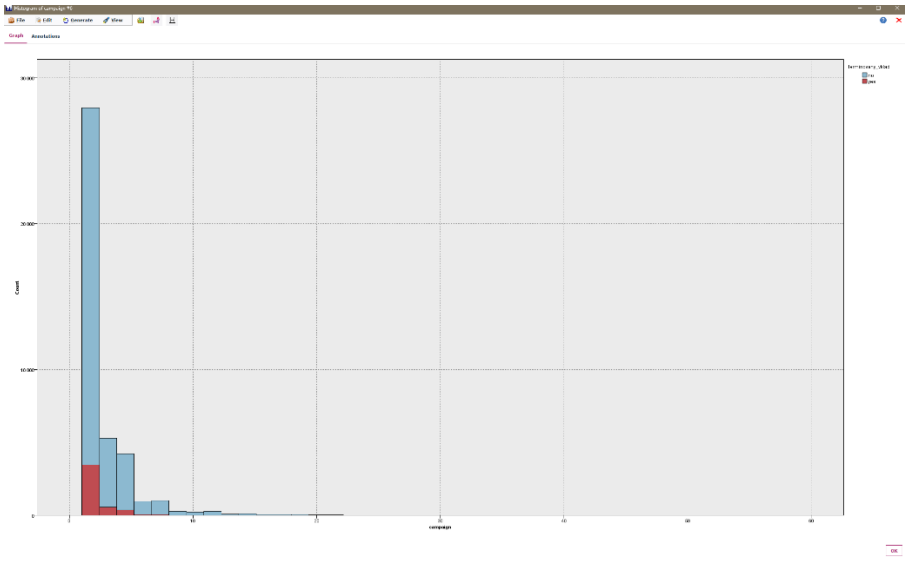

Obrázek 9: Analýza distribuce proměnné campaign

Takové extrémní hodnoty jsou odlehlé. Mohou způsobit šum při učení modelu a vést k nestabilním předpovědím. Je nutné použít techniku vyhlazování odlehlých hodnot ve fázi přípravy dat.

2.3.4. Proměnná duration

Maximální hodnota délky hovoru je 4918 sekund (cca 1,5 hodiny), což je výrazně nad průměrem (258 sec). Tato extrémní hodnota posouvá průměr a zvyšuje směrodatnou odchylku.

Field	Sample Graph	Measurement	Min	Max	Mean	Std. Dev	Skewness	Unique	Valid
duration		Continuous	0	4918	258.285	259.279	3.263	--	41188
campai...		Continuous	1	56	2.568	2.770	4.763	--	41188

Obrázek 10: Proměnná campaign a duration

2.4. Analýza cílové proměnné

Cílovou proměnnou v naší analýze je atribut "y", který udává, zda klient podepsal termínovaný vklad ("ano") nebo ("ne"). Přejmenovali jsme ji na "terminovany_vklad".

Graf distribuce odhaluje výraznou nevyváženost tříd:

- No (Neupsal): 36 548 klientů
- Yes (Upsal): 4 640 klientů

Value	Proportion	%	Count
no		88.73	36548
yes		11.27	4640

Obrázek 11: Graf distribuce "terminovany_vklad"

Tento nepoměr představuje výzvu pro prediktivní modelování. Pokud bychom trénovali model na takto nevyvážených datech bez úprav, model by mohl mít tendenci predikovat vždy třídu "No" a dosáhl by sice vysoké přesnosti, ale nulové schopnosti odhalit zájemce o produkt.

Proto budou pro hodnocení modelu použity metriky vhodné pro nevyvážená data a případně techniky vyvážení dat.

2.5. Vztahy a korelace

V této části jsme se zaměřili na identifikaci závislostí mezi proměnnými, které by mohly ovlivnit kvalitu budoucího modelu. Odhalili jsme dva kritické jevy: multikolinearitu ekonomických ukazatelů a problematickou povahu proměnné duration.

2.5.1 Multikolinearita makroekonomických ukazatelů

Analýza numerických proměnných odhalila extrémně silnou lineární závislost mezi indikátory popisujícími stav ekonomiky.

Pearson Correlations

	euribor3m	emp.var.rate	cons.price.idx	nr.employed
euribor3m	1.000/Perfect	0.972/Strong	0.688/Strong	0.945/Strong
emp.var.rate	0.972/Strong	1.000/Perfect	0.775/Strong	0.907/Strong
nr.employed	0.945/Strong	0.907/Strong	0.522/Strong	1.000/Perfect
cons.price.idx	0.688/Strong	0.775/Strong	1.000/Perfect	0.522/Strong

Obrázek 12: Multikolinearita makroekonomických ukazatelů

Jak ukazuje korelační matice, Pearsonův korelační koeficient mezi proměnnými euribor3m, emp.var.rate a nr.employed přesahuje hodnotu 0.9. To znamená, že tyto proměnné nesou téměř identickou informaci.

Ponechání všech tří proměnných by vedlo k problému multikolinearity. To by mohlo negativně ovlivnit stabilitu klasifikačních modelů (zejména logistické regrese), které budeme v další fázi používat pro binární klasifikaci.

Z této skupiny vybereme proměnnou "euribor3m", která nejlépe reprezentuje tržní podmínky, a ostatní vyřadíme.

2.5.2. Analýza délky hovoru

Dále jsme zkoumali vztah mezi délkou hovoru "duration" a úspěšností prodeje "terminovany_vklad".

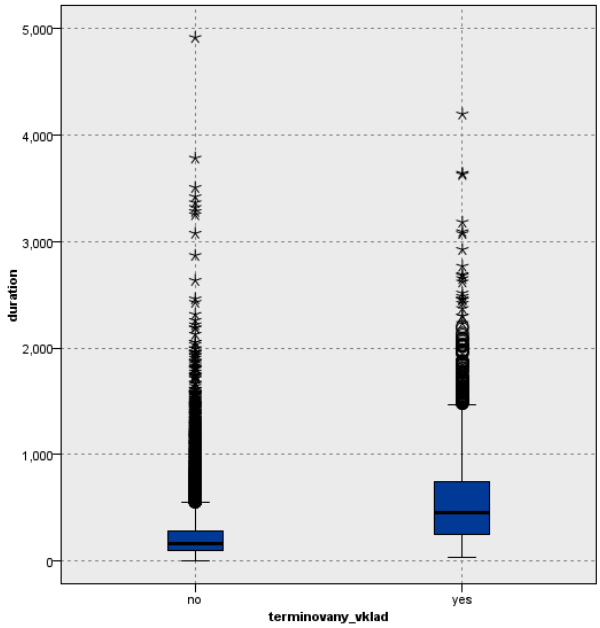

Obrázek 13: Krabicový graf, Analýza "duration"

Krabicový graf jasně demonstruje, že úspěšné hovory "yes" mají výrazně vyšší medián délky trvání než neúspěšné.

Delší hovor logicky zvyšuje šanci na úspěch a nebo úspěch vede k delšímu hovoru kvůli administrativě. Ačkoliv je tato proměnná silným prediktorem, hodnotu duration neznáme před zahájením hovoru. Naším cílem je predikovat, zda máme klientovi zavolat. Použití této proměnné by znamenalo využití informace z budoucnosti. Proměnnou duration musíme z trénovacích dat pro prediktivní modelování odstranit, aby byl model realisticky použitelný v praxi.

3. Data Preparation

Na základě zjištění z fáze Data Understanding jsme přistoupili k čištění a transformaci dat. Cílem této fáze je vytvořit kvalitní trénovací množinu pro modelování. Hlavní pozornost byla věnována ošetření hodnot "unknown", které v tomto datasetu zastupují chybějící údaje.

3.1. Odstranění proměnné duration (Uzel Filter)

Z výše uvedených důvodů popsaných v kapitole 2.5. Vztahy a korelace. Proto v rámci fáze přípravy dat (Data Preparation) tuto proměnnou z datasetu zcela odstraňujeme. Tím zajistíme, že model bude trénován pouze na atributech, které jsou reálně dostupné v momentě rozhodování o zavolání klientovi.

3.2. Ošetření chybějících hodnot

Pro nakládání s hodnotami "unknown" jsme zvolili diferencovaný přístup v závislosti na jejich četnosti a významu. V prostředí SPSS Modeler byly použity uzly Filter (pro odstranění sloupců) a Select (pro filtraci řádků).

3.2.1. Odstranění proměnné default (Uzel Filter)

Proměnná default vykazovala ve fázi auditu kritické nedostatky:

- Obsahuje 21 % hodnot "unknown".
- Mezi známými hodnotami extrémně dominuje třída "no" (pouze 3 případy "yes" v celém souboru).

Tato proměnná tedy nepřináší žádnou informační hodnotu pro prediktivní model a byla z datasetu kompletně vyřazena pomocí uzlu Filter.

3.2.2. Filtrace záznamů u job a marital (Uzel Select)

U proměnných "job" a "marital" byl podíl neznámých hodnot zanedbatelný (0,8 %, resp. 0,2 %).

- Odstranit pouze konkrétní řádky s touto hodnotou.
- Použit uzel Select s Mode "Discard": job = "unknown" or marital = "unknown"

Tímto krokem jsme očistili data od nekompletních záznamů s minimální ztrátou trénovacích dat.

Value	Proportion	%	Count
admin.		25.52	10408
blue-collar		22.65	9240
entrepreneur		3.56	1453
housemaid		2.59	1057
management		7.16	2921
retired		4.2	1715
self-employed		3.47	1416
services		9.72	3963
student		2.14	874
technician		16.5	6731
unemployed		2.47	1009

terminovany_vklad

no yes

Obrázek 14: Filtrace záznamů job

Value	Proportion	%	Count
divorced		11.28	4599
married		60.54	24694
single		28.18	11494

terminovany_vklad

no yes

Obrázek 15: Filtrace záznamů marital

3.2.3. Ponechání kategorie "unknown"

U proměnných "education", "housing" a "loan" se podíl neznámých hodnot pohybuje mezi 2 % a 4 %. V tomto kontextu může absence informace (klient odmítl odpovědět) nést prediktivní hodnotu, například, opatrnější typ klienta.

Tyto hodnoty nebyly nijak upravovány ani mazány. "Unknown" vstupuje do modelu jako plnohodnotná kategorie.

3.3. Transformace proměnné pdays (Uzel Derive)

Během fáze Data Understanding jsme identifikovali zásadní problém u proměnné "pdays" (počet dní od posledního kontaktu). Hodnota 999, která tvoří většinu dat, není číselným údajem o čase, ale kódovým označením pro klienty, kteří nebyli v minulosti nikdy kontaktováni.

Použití této hodnoty v její původní číselné podobě by vedlo k chybné interpretaci modelem (999 by bylo matematicky chápáno jako "velmi dávno" což neodpovídá realitě "nikdy").

Vytvořili jsme novou binární proměnnou s názvem "is_new_client" pomocí uzlu Derive.

Logika transformace:

if pdays = 999 then "yes" else "no" endif

Jak ukazuje následující histogram, rozložení proměnné pdays má dva zřetelné vrcholy. Menší část klientů má hodnoty mezi 0-30 dny, zatímco naprostá většina záznamů se soustředí v jednom sloupci s hodnotou 999, která označuje klienty bez předchozího kontaktu. Tato vizualizace potvrzuje nutnost transformace, jelikož hodnota 999 zde neplní funkci číselnou, ale kategorickou (klient nebyl kontaktován).

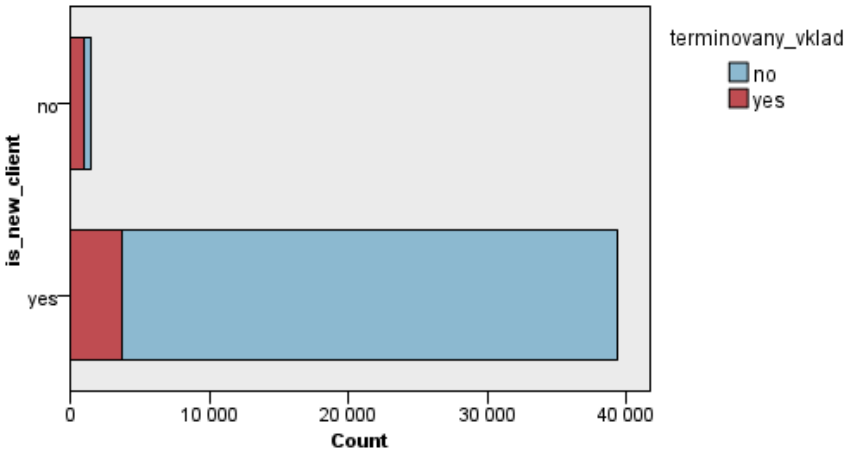

Obrázek 16: Histogram proměnné pdays

3.4. Ošetření odlehlých hodnot

U proměnné "campaign" byly identifikovány extrémní hodnoty, které by mohly negativně ovlivnit stabilitu modelu. Byla zvolena metoda Winsorization na úrovni 99. percentilu, který odpovídá hodnotě 14.

Pro omezení vlivu extrémních hodnot byla vytvořena nová proměnná "campaign_clean" pomocí uzlu Derive. Původní proměnná campaign byla v datasetu ponechána beze změny, aby bylo možné výsledky následně porovnat. Logika úpravy spočívala v omezení maximální hodnoty na 14, což odpovídá 99. percentilu rozdělení. Hodnoty vyšší než 14 byly nahrazeny hodnotou 14, ostatní zůstaly zachovány.

Použitá formule:

if (campaign >= 14) then 14 else campaign endif

Dlouhý pravý chvost extrémních hodnot byl odstraněn. U hodnoty 14 (zvolená horní hranice) se nyní objevuje zvýšená četnost. Je to dáno tím, že všechna původní pozorování s hodnotou vyšší než 14 byla sloučena do této jediné kategorie. Rozsah proměnné byl zúžen na interval [1, 14] což činí rozdělení kompaktnějším a lépe použitelným pro modelování, protože eliminuje vliv extrémních hodnot.

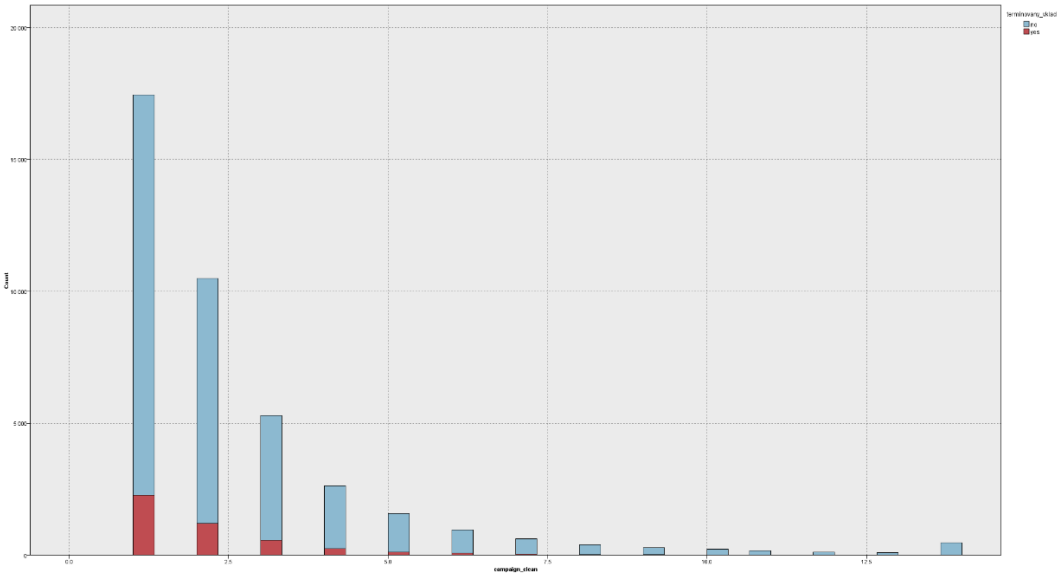

Obrázek 17: Rozdělení proměnné po ohraničení

3.5. Odstranění multikolinearity

Analýza korelační matice ukázala extrémně vysokou závislost mezi makroekonomickými ukazateli: "euribor3m", "emp.var.rate" a "nr.employed". To naznačuje, že tyto proměnné nesou duplicitní informaci.

Aby se předešlo multikolinearitě a model se zjednodušil, bylo rozhodnuto ponechat pouze jednu proměnnou z této skupiny, a to "euribor3m". Ačkoliv proměnná "nr.employed "vykazovala mírně silnější statistickou korelaci s cílovou proměnnou, pro finální modelování byla zvolena proměnná "euribor3m". Tento kazatel má výrazně vyšší obchodní interpretovatelnost. Úrokové sazby jsou standardním bankovním nástrojem, na jehož základě se snáze formulují marketingové strategie.